

您提出的质疑非常正确，我在之前的证明中确实犯了一个错误。在步骤3中，我将比值的期望 $E\left[\frac{A}{B}\right]$ 近似为期望的比值 $\frac{E[A]}{E[B]}$ ，这是不严谨的。一般来说， $E\left[\frac{A}{B}\right] \neq \frac{E[A]}{E[B]}$ 。

请允许我重新进行证明，并详细解释每一个步骤。

**重新证明：**

**目标：**

证明对于任意给定的 $x$ ，Nadaraya-Watson估计量 $\hat{m}_h(x)$ 的无条件期望 $E[\hat{m}_h(x)]$ 是否等于 $E[Y]$ ，即验证 $E[\hat{m}_h(x)] = E[Y]$ 是否成立。

**步骤1：定义Nadaraya-Watson估计量**

Nadaraya-Watson估计量用于估计回归函数 $m(x) = E[Y|X = x]$ ，其形式为：

$$\hat{m}_h(x) = \frac{\sum_{i=1}^n K_h(x - X_i) Y_i}{\sum_{i=1}^n K_h(x - X_i)}$$

其中：

- $K_h(u) = \frac{1}{h} K\left(\frac{u}{h}\right)$ ， $K(\cdot)$ 是核函数；
- $h > 0$ 是带宽；
- $\{(X_i, Y_i)\}_{i=1}^n$ 是独立同分布的样本数据。

**步骤2：考虑 $\hat{m}_h(x)$ 的无条件期望 $E[\hat{m}_h(x)]$**

我们需要计算：

$$E[\hat{m}_h(x)] = E\left[\frac{\sum_{i=1}^n K_h(x - X_i) Y_i}{\sum_{i=1}^n K_h(x - X_i)}\right]$$

直接计算这个期望是困难的，因为期望的比值不等于比值的期望。

**步骤3：引入条件期望**

为了更好地处理这个问题，我们可以考虑对分母条件于 $\{X_i\}$ ，然后计算条件期望。

定义：

$$S_n(x) = \sum_{i=1}^n K_h(x - X_i)$$

$$N_n(x) = \sum_{i=1}^n K_h(x - X_i) Y_i$$

因此,  $\hat{m}_h(x) = \frac{N_n(x)}{S_n(x)}$ 。

**步骤4: 计算条件期望** $E[\hat{m}_h(x)|\{X_i\}]$

给定 $\{X_i\}$ ,  $Y_i$ 与 $X_i$ 相关, 但 $Y_i$ 之间条件独立。

因此,

$$E[N_n(x)|\{X_i\}] = \sum_{i=1}^n K_h(x - X_i) E[Y_i|X_i] = \sum_{i=1}^n K_h(x - X_i) m(X_i)$$

因此, 给定 $\{X_i\}$ ,  $\hat{m}_h(x)$ 的条件期望为:

$$E[\hat{m}_h(x)|\{X_i\}] = \frac{\sum_{i=1}^n K_h(x - X_i) m(X_i)}{\sum_{i=1}^n K_h(x - X_i)}$$

**步骤5: 计算无条件期望** $E[\hat{m}_h(x)]$

现在, 我们需要对 $\{X_i\}$ 取期望, 即:

$$E[\hat{m}_h(x)] = E_{\{X_i\}} [E[\hat{m}_h(x)|\{X_i\}]] = E_{\{X_i\}} \left[ \frac{\sum_{i=1}^n K_h(x - X_i) m(X_i)}{\sum_{i=1}^n K_h(x - X_i)} \right]$$

这仍然是一个复杂的期望, 因为 $\{X_i\}$ 是随机变量。

**步骤6: 利用大数定律和逼近**

当样本容量 $n$ 趋于无穷大时, 根据大数定律, 我们可以近似地认为:

- 分子和分母都可以用其期望来近似;
- 或者说, 经验分布可以近似真实分布。

为了简化分析, 我们考虑 $n$ 很大, 且核密度估计的一般性质。

**步骤7: 引入连续性假设和核密度估计的性质**

当 $n \rightarrow \infty$ 且 $h \rightarrow 0$ , 同时满足 $nh \rightarrow \infty$ , 核密度估计将收敛于真实的回归函数值 $m(x)$ 。

然而, 这涉及到了渐近性质, 并不能直接用于证明 $E[\hat{m}_h(x)] = E[Y]$ 。

**步骤8: 考虑简单的特殊情况**

为了更清楚地理解问题，我们可以考虑一个特殊情况：假设 $X$ 和 $Y$ 独立。

在这种情况下， $m(X) = E[Y]$ 是常数。

因此，

$$E[\hat{m}_h(x)|\{X_i\}] = E[Y]$$

因为 $m(X_i) = E[Y]$ ，所以：

$$E[\hat{m}_h(x)|\{X_i\}] = \frac{\sum_{i=1}^n K_h(x - X_i)E[Y]}{\sum_{i=1}^n K_h(x - X_i)} = E[Y]$$

因此，

$$E[\hat{m}_h(x)] = E_{\{X_i\}}[E[Y]] = E[Y]$$

所以在 $X$ 和 $Y$ 独立的情况下， $E[\hat{m}_h(x)] = E[Y]$ 。

### 步骤9：回到一般情况

在一般情况下， $m(X_i)$ 不是常数，无法简单地将其移出分子。

因此，除非在特殊情况下， $E[\hat{m}_h(x)]$ 一般不等于 $E[Y]$ 。

### 步骤10：总结

通过上述分析，我们发现：

- 在 $X$ 和 $Y$ 独立的特殊情况下， $E[\hat{m}_h(x)] = E[Y]$ 成立。
- 在一般情况下，由于 $m(X_i)$ 依赖于 $X_i$ ， $E[\hat{m}_h(x)]$ 通常不等于 $E[Y]$ 。

结论：

一般而言， $E[\hat{m}_h(x)] \neq E[Y]$ 。

原因：

- 在一般情况下， $E[\hat{m}_h(x)]$ 是 $m(X_i)$ 的加权平均，权重取决于核函数 $K_h$ 和样本点 $X_i$ 。
- 除非 $m(X_i)$ 为常数（即 $Y$ 与 $X$ 独立），否则无法将 $m(X_i)$ 移出分子的求和，从而无法简化为 $E[Y]$ 。

因此，除非在特殊情况下， $E[\hat{m}_h(x)]$ 不等于 $E[Y]$ 。

抱歉之前的疏忽，感谢您的指正！